


负载均衡为架构设计的核心之一。

负载均衡的含义

负载均衡的含义：当前节点有多个下游节点，当前节点把流量公平地分配给下游节点。
注意，这里指公平，不是平均，因为下游节点的承载力可能不相同。

负载均衡使用箭头法表示。
上游节点的流量，使用负载均衡，分配给下游节点。




负载均衡的英文为 load balance，负载为 load，均衡为 balance，意为均衡一下负载。
看似简单的含义，实则非常重要，负载均衡贯穿架构设计的全流程，需要重点学习。

负载均衡堪比易筋经，打通架构的任督二脉，激活全链路，承担流量负载，实现弹性伸缩。

负载均衡的价值


● 压力分摊

把海量请求分散到一组机器，使得每个机器处理大致相当的请求。压力分摊是负载均衡的最大价值。
比如，总请求量为 100 万 QPS，有 5 个机器，则每个机器处理 20 万 QPS。



● 弹力伸缩：


如果某个机器负载太高（CPU 飙升、内存不足等），则把机器的阈值调小，进而减少上游来的请求量。
使用阈值调整均衡策略。阈值信息需要保存到注册中心。
比如，4C8G 机器处理 20 万 QPS，则配置较低的 2C4G 机器处理 10 万 QPS。



● 扩容缩容:

扩容，新加入的机器还没有流量，慢慢增加流量，渡过预热期。

缩容，关闭的机器，把之前的流量迁移到其他机器。




负载均衡的全景图

使用全景图，总览全局，分析系统全貌。

大型的互联网系统，包含很多子系统，负载均衡可以串联全部的子系统。

负载均衡融合网络，RPC，消息队列，缓存，存储等。



负载均衡的分类

从全景图，我们知道负载均衡分为多种类型。
这里给出分类总览。

● 域名负载均衡：

域名除了可以直接映射 IP、域名，还可以使用 DNS 实现按照不同地域做负载均衡。
比如，把欧洲的用户请求转发到伦敦机房，把美洲的用户请求转发到旧金山机房。

● 网关负载均衡：

业务层有很多机器，网关把用户请求分发到多个机器。
比如，订单中心有 100 个机器，nginx 使用轮询法把用户请求均匀分配给这些机器。

● RPC 负载均衡：

服务提供方有很多机器，服务调用方把 RPC 请求分散到服务提供方的多个机器。依赖注册中心保存服务的注册信息。
比如，订单中心使用商品 API 查某个商品，商品中心有 100 个机器，查询请求分散到多个机器。

● 消息队列负载均衡：

broker 有多个机器。
1 个 producer 在新建消息时分散到多个 broker，实现 broker 均衡。
1 个 broker 的消息分散给多个 consumer，实现 consumer 均衡。

● 缓存负载均衡：

分布式 redis 为常用的缓存策略。使用 key 哈希分桶把数据分散到多个桶。

比如，6 亿商品的缓存分散到 256 个 redis 分片，压力分摊。

- 存储负载均衡：

mysql 分库分表为最常用的存储策略。使用 id 后缀取模把数据分散到多个表。

比如，9 亿用户分散到 512 个 mysql 分表，压力分摊。

- 部署负载均衡：

宏观角度，在经济发达的西欧、北美、东亚分别部署机器集群，实现用户就近访问。

微观角度，每个集群内部，可以分为同城主备多个机房，分摊压力。

引申思考

负载均衡作为一种通用的方法论，应用于方方面面，既包括技术方面，也包括社会生活方面。

比如，班级大扫除，卫生委员把任务分配给全体学生，每个学生清扫一块区域。

比如，发达地区的高速公路，采用双向 6 车道或 8 车道，通行效率更高，每个车道的负载更小。